Qwen3 法律大模型微调手册

一、模型、数据准备

1、在**内蒙B区（要与数据盘在同一个大区）**租用实例，将模型文件、llamafactory解压到autodl-tmp 目录下，将数据文件复制到autodl-tmp目录下

这里模型文件、数据文件已经上传好，下载地址为：

模型：https://www.modelscope.cn/models/Qwen/Qwen3-4B

数据（huggingface）：https://hf-mirror.com/datasets/ShengbinYue/DISC-Law-SFT?row=50

数据（modelscope）：https://modelscope.cn/datasets/Robin021/DISC-Law-SFT/files

打开终端运行如下命令：

```
#解压llamafactory到autodl-tmp
unzip ~/autodl-fs/LLaMA-Factory.zip -d ~/autodl-tmp

#解压qwen到autodl-tmp
unzip ~/autodl-fs/Qwen3-4B.zip -d ~/autodl-tmp


#复制数据集到autodl-tmp
cp ~/autodl-fs/DISC-Law-SFT-Triplet-released.jsonl ~/autodl-tmp/

#安装依赖
cd autodl-tmp/LLaMA-Factory/
pip install -e .[metrics,modelscope,qwen]

```

检查一下cuda环境

```
#命令行输入python
import torch

if torch.cuda.is_available():
    print("CUDA is available! You can use GPU.")
else:
    print("CUDA is not available. Using CPU.")

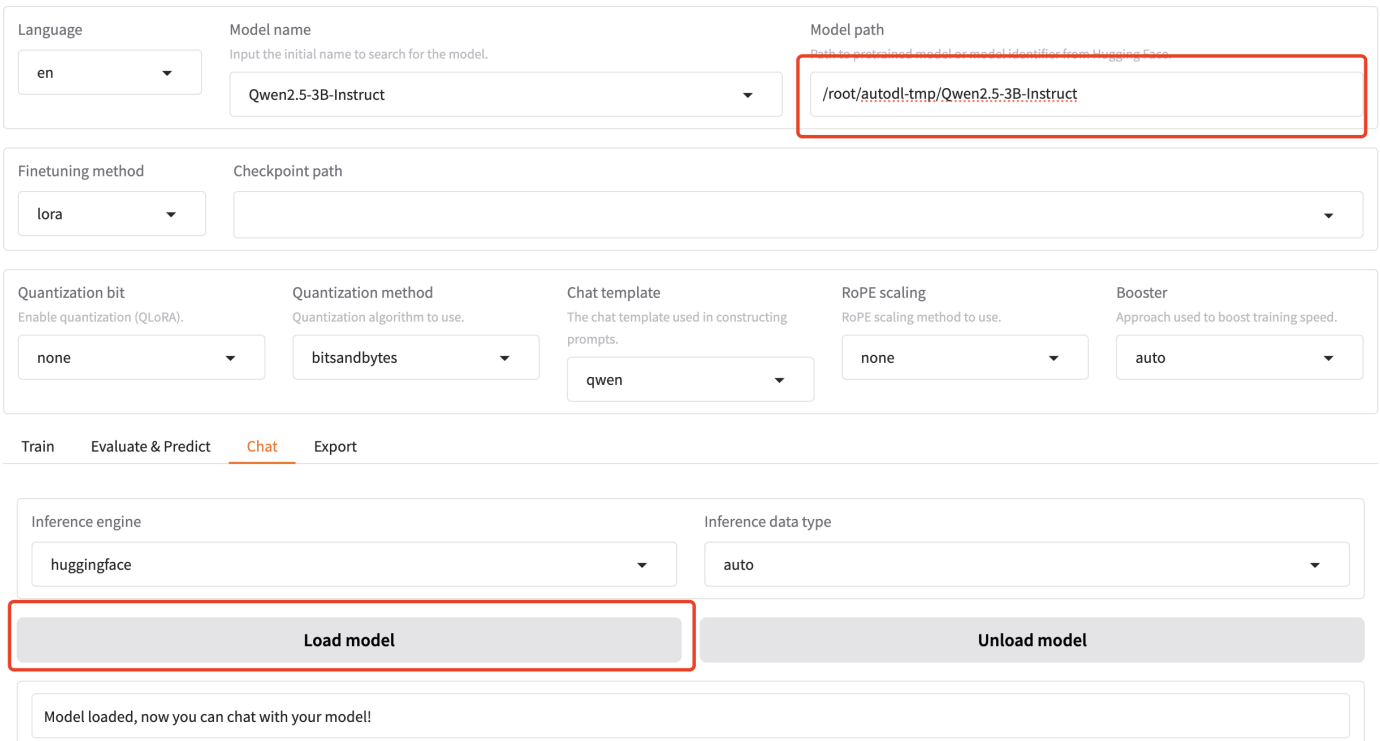
exit()
```

```
10
11  #看一下显卡情况
12  nvidia-smi
```

二、LLaMA Board 可视化微调（由 Gradio 驱动）

```
1   llamafactory-cli webui
2
3   为了在本地打开llamafactory微调页面需要打开本地终端，运行以下命令：
4   首先查看autodl ssh和密码
5   以以下ssh和密码为例
6   ssh：ssh -p 44146 root@connect.nmb1.seetacloud.com
7   密码：IoiGFqiIuZkh
8
9   则本地运行命令为：
10  ssh -CNgv -L 7860:127.0.0.1:7860 root@connect.nmb1.seetacloud.com -p 44146
11
12  运行成功后在浏览器地址栏输入：
13  http://127.0.0.1:7860/
```

2.1 模型加载　以下model-name和model path模型替换为Qwen3-4B



2.2 数据集处理

新建data_process.py，黏贴以下命令

```
import json

# 读取以.jsonl结尾的文件
json_data = []
with open('/root/autodl-tmp/DISC-Law-SFT-Triplet-released.jsonl', 'r',
encoding='utf-8') as file:
    for line in file:
        print(line)
        data = json.loads(line)
        json_data.append(data)
# 待填入的模板
template = []

# 遍历json数据集
for idx, data in enumerate(json_data[:]):
   conversation = [
       {
           "from": "human",
           "value": data["input"]
       },
       {
           "from": "gpt",
           "value": data["output"]
       }

   ]

   template.append({

       "conversations": conversation,
       "system": "",
       "tools": ""
   })
print(len(template))
# 输出填充数据后的模板
print(json.dumps(template[2], ensure_ascii=False, indent=2))
# 将template写入到本地文件
output_file_path = "/root/autodl-tmp/LLaMA-Factory/data/train_data_law.json";
with open(output_file_path, 'w', encoding='utf-8') as f:
   json.dump(template, f, ensure_ascii=False, indent=2)
```

```
40
41  print(f"处理好的数据已写入到本地文件:{output_file_path}")
```



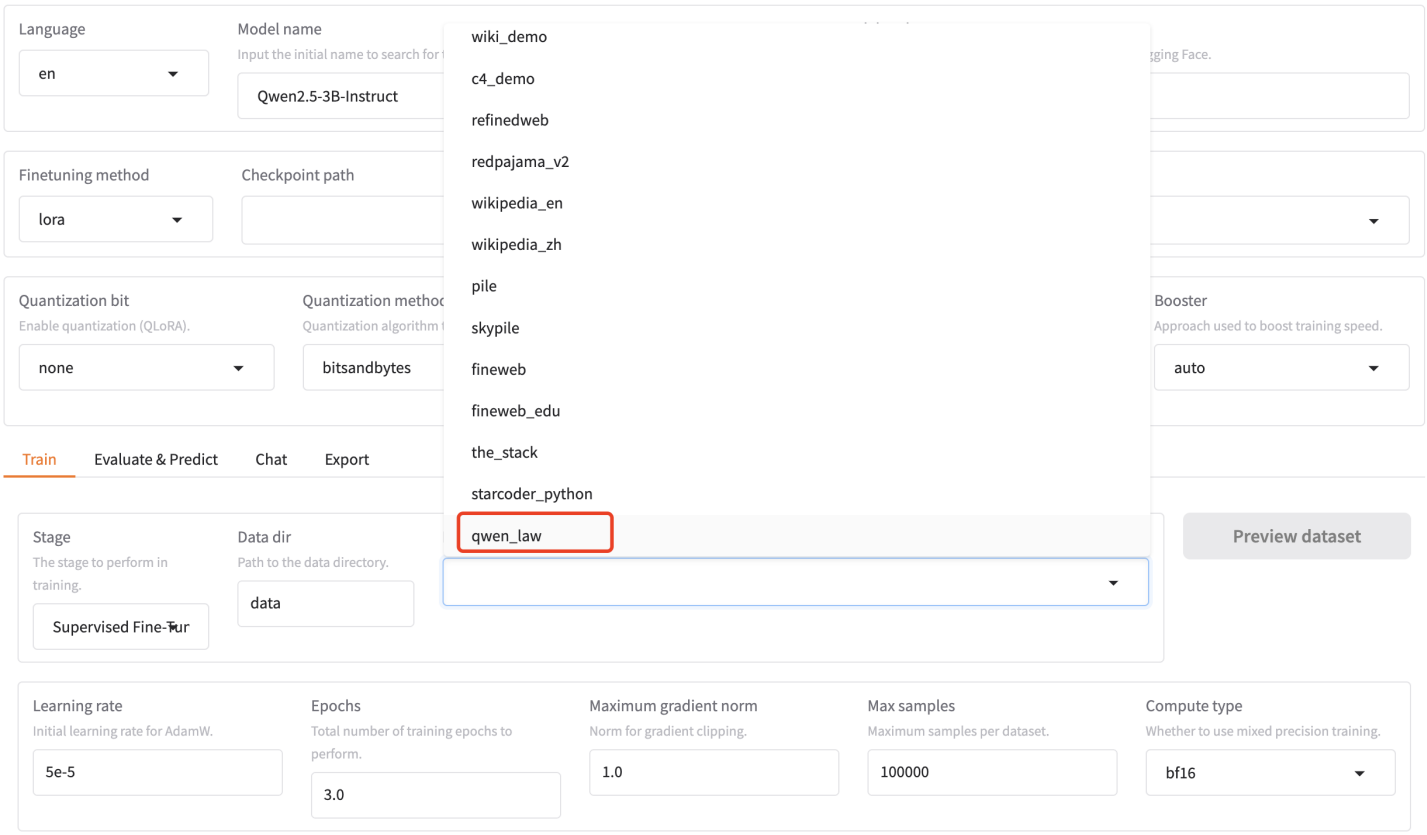
看到以上文件，数据处理完成，共16000条sft数据

打开dataset_info.json这个文件，添加以下代码，把数据集添加到可选列表中

```
1    "qwen_law": {
2      "formatting":"sharegpt",
3      "file_name": "train_data_law.json",
4      "columns": {
5        "messages": "conversations",
6        "system": "system",
7        "tools": "tools"
8      },
9      "tags": {
10       "role_tag": "from",
11       "content_tag": "value",
```

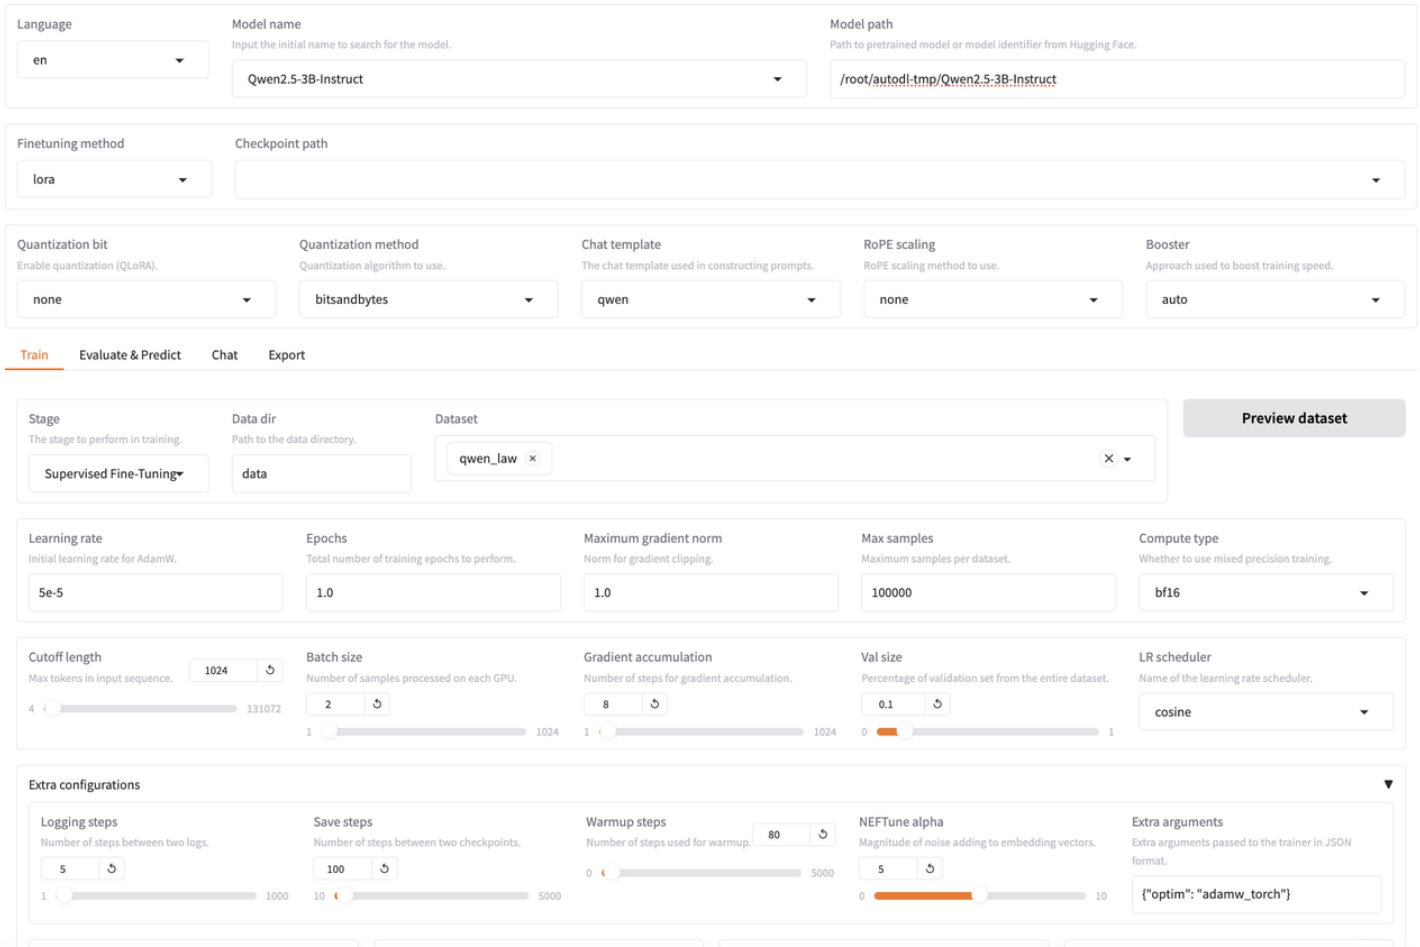
```
        "user_tag": "human",
        "assistant_tag": "gpt"
    }
```

接下来可以看到数据集可以选择：



2.3 模型训练

模型参数设置如下：



下面逐个解释这些参数的含义：

1. **Language**
   语言选择项，这里选的是“en”，表示使用英文。
2. **Model name**
   这里指定了模型名称（`Qwen2.5-3B-Instruct`），它表明使用的是一个名为Qwen2.5-3B-Instruct的模型。
3. **Model path**
   这是预训练模型的路径，指向本地或Hugging Face上的预训练模型。
4. **Finetuning method**
   选择微调方法，这里选的是“lora”，一种微调方法。
5. **Checkpoint path**
   用于指定检查点路径，保存模型训练的中间状态。
6. **Quantization bit**
   量化位数，用来决定是否启用量化（QLoRA）。这里选择“none”，表示不启用量化。
7. **Quantization method**
   量化方法，指使用哪种量化算法，这里选择了“bitsandbytes”作为量化方法。
8. **Chat template**
   用于生成聊天输入模板，选择了“qwen”，指使用Qwen的模板。

9. **RoPE scaling**
   RoPE缩放方法，用于模型训练过程中的缩放调整。这里选择了“none”，表示不使用RoPE缩放。
10. **Booster**
    提升训练速度的策略，这里选择了“auto”，表示自动选择最佳的加速方法。
11. **Stage**
    模型训练的阶段，这里选择了“Supervised Fine-Tuning”，表示进行监督学习微调。
12. **Data dir**
    数据目录，指定数据存储的位置。
13. **Dataset**
    选择使用的数据集，这里选择了“qwen_law”。
14. **Learning rate**
    学习率，用于控制训练过程中的更新步长。这里设为5e-5，表示非常小的学习率。
15. **Epochs**
    训练的总轮次，这里设置为3.0，表示训练3轮。
16. **Cutoff length**
    输入序列的最大标记数，限制了输入的最大长度，这里设为1024，表示最大长度为1024个标记。
17. **Batch size**
    批处理大小，每次训练使用的数据样本数量。这里设为8，表示每次训练使用8个样本。
18. **Maximum gradient norm**
    梯度裁剪的最大值，用来防止梯度爆炸。这里设置为1.0，表示最大梯度裁剪为1.
19. **Max samples**
    每个数据集的最大样本数量。这里设置为100000，表示最多处理100,000个样本。
20. **Compute type**
    是否使用混合精度训练，这里选择了“bf16”，表示使用bfloat16精度进行训练。
21. **LR scheduler**
    学习率调度器的名称，这里选择了“cosine”，表示使用余弦退火调度器来调整学习率，逐步降低到0。
22. **NEFTune**

    用于调节与嵌入向量（embedding vectors）相关的噪声幅度。降低过拟合问题

```
Tips：
学习率
学习率设置及调整：
学习率（Learning Rate）是训练深度学习模型时最重要的超参数之一，它决定了在每一步优化过程中，模型的参数更新的幅度。设置学习率过高可能会导致模型训练不稳定或无法收敛，过低则会使训
```

练速度非常慢。

常见设置：

初始学习率通常设置为一个小的值，例如：1e-3、1e-5 或 1e-6，具体数值取决于任务和模型的复杂性。在此示例中，使用的是 5e-5，表示比较小的学习率，适用于一些大规模的预训练模型的微调。

调整学习率的方法：

- **学习率调度器（LR Scheduler）**：可以使用学习率调度器动态调整学习率，常见的策略有：
- **余弦退火（Cosine Annealing）**：学习率随着训练轮次逐渐减少，并在最后几轮中保持较小的值。
- **学习率热身（Warmup）**：从一个较小的学习率开始，然后逐渐增加，避免在训练初期震荡。
- **减少学习率（Reduce on Plateau）**：当验证集的性能没有提升时，自动减小学习率。

基于训练结果调整：

- **观察损失（Loss）变化**：如果发现损失开始上升，或者训练结果不稳定，可能需要降低学习率。
- **早停（Early Stopping）**：如果损失不再显著减少，可以通过提前停止训练来避免过拟合，或者调整学习率继续训练。

RoPE scaling（RoPE缩放）：

RoPE（Rotary Positional Encoding，旋转位置编码）是一种新的位置编码方法，在一些大型模型（如GPT类模型）中用于处理序列的位置信息。RoPE可以帮助改进模型在长序列上的表现，避免传统的绝对位置编码方法在处理长文本时出现的效果衰减问题。

RoPE scaling 是指对 RoPE 的位置编码进行缩放的操作，RoPE缩放的核心思想是 **调节旋转幅度**，即对旋转位置编码中的参数进行缩放，以优化模型对不同长度序列的处理能力。具体来说，**缩放** 是指对位置编码的旋转角度或幅度进行动态调整，从而使模型在训练过程中根据需要更加关注不同的位置和距离。为了调整位置编码与模型训练中的其他参数的配合。不同的缩放方法可以影响模型对不同序列长度的处理能力。设置为“none”表示不使用RoPE缩放，使用默认的或其他方式来处理位置编码。

具体来说，RoPE位置编码通过在模型的多头注意力机制中使用旋转变换，将每个位置的向量“旋转”以避免相对位置信息丧失，这样在处理长文本时能有效增强模型的表示能力。

2.4 模型合并输出

以上训练的是Lora层，要将Lora和主模型合并，进行输出

Language

en

Model name

Input the initial name to search for the model.

Qwen2.5-3B-Instruct

Model path

Path to pretrained model or model identifier from Hugging Face.

/root/autodl-tmp/Qwen2.5-3B-Instruct

Finetuning method

lora

Checkpoint path

train_2025-02-15-10-10-47

Quantization bit

Enable quantization (QLoRA).

none

Quantization method

Quantization algorithm to use.

bitsandbytes

Chat template

The chat template used in constructing prompts.

qwen

RoPE scaling

RoPE scaling method to use.

none

Booster

Approach used to boost training speed.

auto

Train | Evaluate & Predict | Chat | Export

Max shard size (GB)

The maximum size for a model file.

5

1 100

Export quantization bit.

Quantizing the exported model.

none

Export quantization dataset

The calibration dataset used for quantization.

data/c4_demo.json

Export device

Which device should be used to export model.

cpu auto

Do not use safetensors to save the model.

Export legacy format

Export dir

Directory to save exported model.

/root/autodl-tmp/Qwen2.5-3B-Instruct_law

HF Hub ID (optional)

Repo ID for uploading model to Hugging Face hub.

Export